

item	zapis postaci	właściwości
Funkcja logistyczna	$f(z) = \frac{1}{1+e^{-z}}$	$\lim_{z \rightarrow -\infty} = 0, \lim_{z \rightarrow \infty} = 1$
odds	$Odds = \frac{p}{1-p}$	Iloraz prawdopodobieństwa zajścia zdarzenia i nie zajścia, z (0,1) do (0, nieskończoność)
logit	$\ln(p/(1-p))$	transformuje zmienna z zakresu 0-1 na zakres -∞, +∞
ryzyko względne (RR)	$\frac{P(Y=1 X_1=1, X_2, X_3 \dots - const)}{P(Y=1 X_1=0, X_2, X_3 \dots - const)}$	Ile razy prawdopodobieństwo zajścia zdarzenia jest większe w grupie $x_1=1$ (eksperymentalna) niż w grupie $x_1=0$ (kontrolna)
iloraz odds (OR)	$OR = \frac{Odds \text{ dla } X_1}{Odds \text{ dla } X_0} = \frac{\frac{P(X_1)}{1-P(X_1)}}{\frac{P(X_0)}{1-P(X_0)}}$	Ile razy szanse zajścia są większe w grupie $x_1=1$ niż $x_1=0$
model logistyczny	$P(X) = \frac{1}{1+e^{-(\alpha+\beta X)}}$ $logit(A = a_1) = \log(odds(A = a_1))$ $= \log(P(A = a_1)/(1 - P(A = a_1)))$ $= \alpha + \beta X$	funkcja logitowa - do przekształcania prawdopodobieństwa na logarytm ilorazu szans:
model EVW	$logit P(X) = \alpha + \beta E + \gamma V + \delta W$ (wektorowy zapis)	E- efekt główny (wystawienie na ryzyko) V - potencjalnie zakłócające, W - potencjalnie modyfikujące efekty główne.
model EVW dla par połączonych	$logit P(X) = \alpha + \beta E + \gamma_1 V_1 + \gamma_2 V_2 + \delta W$	Dodane zmienne 0-1 oznaczające status parowania przez niektóre zmienne C (control) np. płeć oznaczone V_1

test zgodności Hosmera Lemeshowa	$H = \sum_{i=1}^G \frac{(O(1i)-E(1i))^2}{E(1i)} + \frac{(O(0i)-E(0i))^2}{E(0i)}$ <p>ma rozkład χ^2 z G-2 stopniami swobody, gdzie G to liczba grup (najczęściej 10)</p>	Test sprawdza, czy przewidywane liczby zdarzeń w podgrupach zbioru danych zgadzają się z rzeczywiście obserwowaną liczbą zdarzeń. Umożliwia stwierdzenie czy regresja logistyczna zwraca prawdopodobieństwo
krzywa ROC	<p>oś x -> 1- specificity= 1- TN/(TN+FP)</p> <p>oś y -> sensitivity = (TP)/(TP+FN)</p>	umożliwia jednoczesną ocenę czułości i swoistości modelu. Im krzywa ROC jest bardziej wypukła tym model jest lepszy (większe prawd op., że dobrze ustawimy próg odcięcia)

PROC LOGISTIC Statement Options

Option

Input/Output Data Set Options

COYOUT = *20 cases, missing boundary*

DATA = *data set*

INEST =

INMODEL =

NOOXY

OUTDESIGN =

OUTDESIGNONLY

OUTTEST =

OUTMODEL =

Response and CLASS Variable Options

DESCENDING *maybe variable 1st, 2nd perhaps last, 1st, 2nd*

NAMELEN =

ORDER =

TRUNCATE

Displayed Output Options

ALPHA =

NOPRINT

PLOTS (none) = all *maybe variable method - 1st*

SIMPLE

Large Data Set Option

MULTIPASS

Control of Other Statement Options

EXACTONLY

EXACTOPTIONS

ROOOPTIONS *defaulting app to output language RDC*

2. Zapisz relacje pomiędzy Odds & prawdopodobieństwem

$$\text{Odds (zdarzenie)} = \frac{p}{1-p}$$

$$p = \frac{p}{p+q}$$

$$p = \frac{p}{1+q/p}$$

$$p(1+q/p) = p$$

$$\text{Prawdopodobieństwo (zdarzenie)} = \frac{O}{1+O}$$

3. Jeśli prawdopodobieństwo wystąpienia zdarzenia $p = 0.6$, ile wynosi Odds dla A.

$$O = \frac{0.6}{1-0.6} = \frac{0.6}{0.4} = \frac{3}{2}$$

OK

4. Wyniki estymacji funkcji logitowej są następujące: $\ln p(Y=1|X) = 1.8386 + 0.2131X$ dla dychotomicznej X. Ile wynoszą Odds dla $Y=1, X=1$, względem $X=0$?

$$p(1) = 1.8386 + 0.2131 \cdot 1 \approx 2.05$$

$$p(0) = 1.8386 + 0.2131 \cdot 0 \approx 1.84$$

$$\text{dla } X=1 \rightarrow \frac{p(1)}{p(0)}$$

$$\text{dla } X=0 \rightarrow \frac{p(0)}{p(0)}$$

5. Wyjaśnij różnicę w metodach estymacji: MLSE i RMLSE - stosowanych do estymacji modeli regresji

MLM jest szacowana następująco:

$$L = p(Y=y_1) \cdot p(Y=y_2) \cdot p(Y=y_3) \cdot \dots = \prod_{i=1}^n p_i(y_i)$$

$$= \max(L)$$

$$I_0 = 0$$

$$u_0 = 0$$

W metodzie RMLM użyjemy normalizacji

2. Zapisz relację między odds a prawdopodobieństwem
 $p = \text{odds} / (\text{odds} + 1)$

odds=p/(1-p)

3. Jeżeli prawdopodobieństwo wystąpienia zdarzenia $c = 0,6$ jakie jest odds

odds=0,6/(1-0,6)=1,5

4. Wynik estymacji funkcji logistycznej są następujące: $p(x,y)=1,9386 * y + 0,231 * x$ dla dychotomicznej zmiennej x . Ile wynosi odds dla $y=1|x=1$ względem $y=1|x=0$?

$$OR = \frac{\text{Odds dla } X1}{\text{Odds dla } X0} = \frac{\frac{P(X1)}{1-P(X1)}}{\frac{P(X0)}{1-P(X0)}}$$

$p1 = 1/(1+e^{-(1,9386 * 1 + 0,231 * 1)}) = 0,89749$

$p0 = 1/(1+e^{-(1,9386 * 1 + 0,231 * 0)}) = 0,87420$

$\text{Odds1} = p1/(1-p1) = 8,754781$

$\text{Odds0} = p0/(1-p0) = 6,949016$

$OR = \text{Odds1}/\text{Odds0} = 1,259859$ -

OR = TO SAMO WYJDZIE JAK OBLICZYMY $\exp(0.231)$

czyli $\exp(z1-z2)$, gdzie z to logit tego modelu

5. Wyjaśnij różnicę w metodach estymacji MLM i RMLM stosowanych do estymacji modeli regresji

MLM - https://en.wikipedia.org/wiki/Multilevel_model ?

Maximum Likelihood Method - a method of **estimating** the **parameters** of a **statistical model** given observations, by finding the parameter values that maximize the **likelihood** of making the observations given the parameters.

Suppose there is a sample x_1, x_2, \dots, x_n of n **independent and identically distributed**

observations, coming from a distribution with an unknown **probability density function** $f_0(\cdot)$. It is

however surmised that the function f_0 belongs to a certain family of distributions $\{ f(\cdot | \theta), \theta \in$

$\Theta \}$ (where θ is a vector of parameters for this family), called the **parametric model**, so that $f_0 =$

$f(\cdot | \theta_0)$. The value θ_0 is unknown and is referred to as the *true value* of the parameter vector. It is

desirable to find an estimator **theta** which would be as close to the true value θ_0 as possible.

Either or both the observed variables x_i and the parameter θ can be vectors.

Robust Maximum Likelihood Method - gdzie założeniem również jest że dane mają wielowymiarowy rozkład normalny ale kurtioza jest mniejsza lub większa niż 3, [normalna dla normalnego =3]

-

6. Zakładając, że do estymacji modelu regresji logistycznej wykorzystano następujące zmienne: D (hipertensja (0,1); $X_1 = \text{AGE}$ (zmienna ciągła); $X_2 = \text{SMK}$ (0,1); $X_3 = \text{SEX}$ (0,1); $X_4 = \text{CHOL}$ (cholesterol, zmienna ciągła); $X_5 = \text{OCC}$ - Occupation (0,1). Otrzymało następujące wyniki estymacji modelu:

Zmienne	Współczynniki
Constant	-4,32
AGE	0,0274
SMK	0,5859
SEX	1,1523
CHOL	0,0087
OCC	-0,5309

Polecenia:

1. Zapisz postać oszacowanego modelu regresji logistycznej

$$-4,32 + 0,0274 \cdot X_1 + 0,5859 \cdot X_2 + \text{SEX} \cdot 1,1523 + \text{CHOL} \cdot 0,0087 + \text{OCC} \cdot (-0,5309)$$

2. Zapisz postać wyestymowanego modelu w postaci logitu

3. Oblicz na podstawie modelu oszacowane ryzyko, zakładając, że, badany jest mężczyzna w wieku 40 lat ($\text{SEX}=1$), o wartościach zmiennych: $\text{SMK}=1$; $\text{CHOL}=200$; $\text{OCC}=1$, podaj interpretację otrzymanego wyniku.

$$R = -4,32 + 0,5859 \cdot 1 + 200 \cdot 0,0087 + 1 \cdot 1,1523 + 1 \cdot (-0,5309) =$$

Interpretacja za pomocą ilorazu szans: e^R

1. zapisz postać oszacowanego modelu regresji logistycznej

$$p_i = 1 / (1 + e^{(-4,32 + 0,0274 \cdot \text{AGE} + 0,5859 \cdot \text{SMK} + 1,1523 \cdot \text{SEX} + 0,0087 \cdot \text{CHOL} - 0,5309 \cdot \text{OCC})})$$

2. zapisz postać wyestymowanego modelu w postaci logitu

$$z_i = -4,32 + 0,0274 \cdot \text{AGE} + 0,5859 \cdot \text{SMK} + 1,1523 \cdot \text{SEX} + 0,0087 \cdot \text{CHOL} - 0,5309 \cdot \text{OCC}$$

3. oblicz na podstawie modelu oszacowane ryzyko, zakładając że badany jest mężczyzna w wieku 40 lat o wartości zmiennych SMK=1 CHOL=200 OCC=1. podaj interpretację

$$R1 = -4,32 + 0,0274 \cdot 40 + 0,5859 \cdot 1 + 1,1523 \cdot 1 + 0,0087 \cdot 200 - 0,5309 \cdot 1 = -0,2767$$

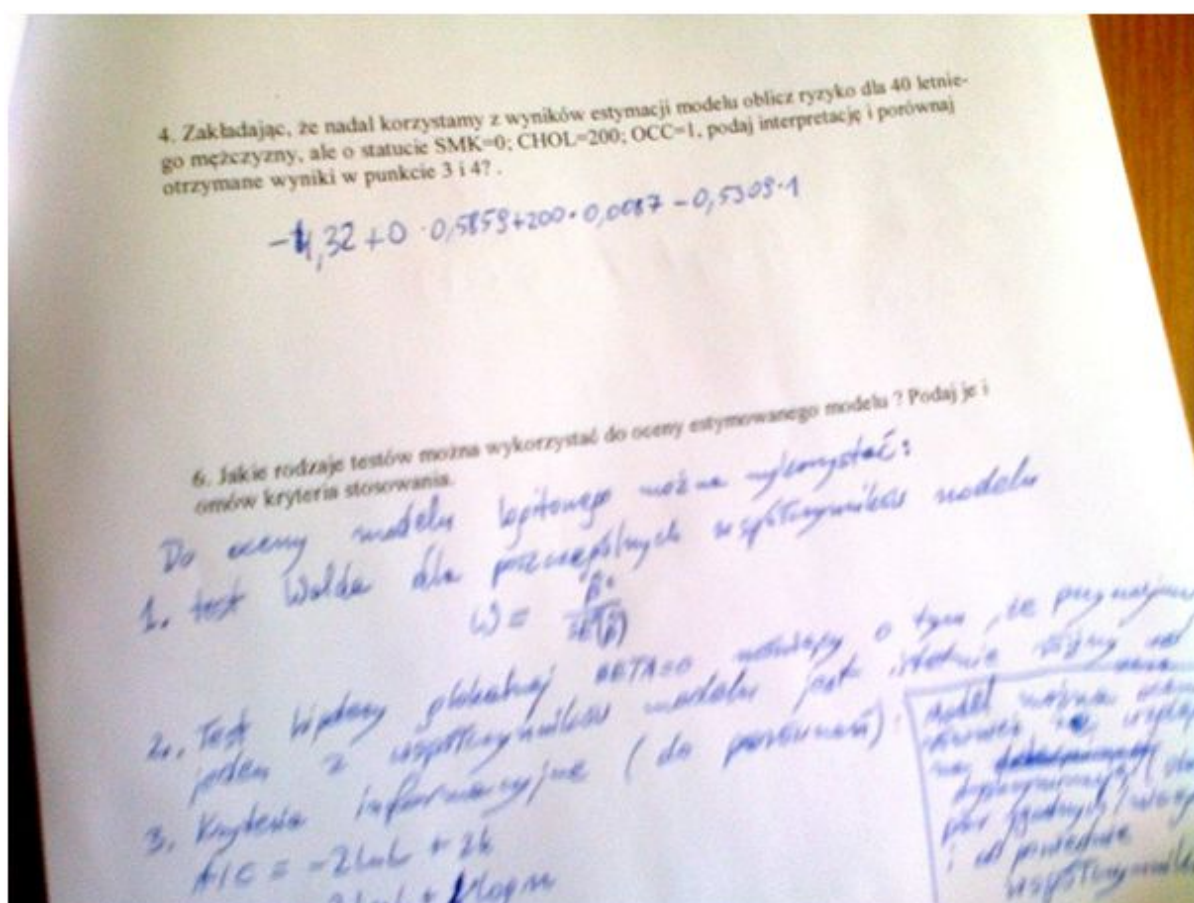
Ryzyko można interpretować jedynie w odniesieniu do innego ryzyka. Można mówić że ryzyko dla jednostki jest większe niż dla innej jednak samo ryzyko nie jest

prawdopodobieństwem ?

A to nie będzie $1/(1+e^{(-[R1])}) = 0,431263$

Interpretacja: Ryzyko zachorowania dla wybranej osoby wynosi 43%

(też mi się tak wydaje)



4. zakładając że nadal korzystamy z wyników estymacji modelu oblicz ryzyko dla 40 letniego mężczyzny w wieku 40 lat o wartości zmiennych SMK=0

CHOL=200 OCC=1. podaj interpretację i porównaj otrzymane wyniki w punkcie 3 i 4

$$R2 = -4,32 + 0,0274 * 40 + 0,5859 * 0 + 1,1523 * 1 + 0,0087 * 200 - 0,5309 * 1 = -0,8626$$

$$RR=R2/R1=-0,8626/-0,2767=3,1175$$

Oznacza to że Ryzyko dla drugiej osoby jest ponad 3 krotnie mniejsze niż dla osoby pierwszej ?

A to nie będzie $1/(1+e^{(-[R2])}) = 0,297$

Interpretacja: Ryzyko zachorowania dla wybranej osoby wynosi 30%

$$RR= P1/P2= 1,45$$

Prawdopodobieństwo zdarzenia dla 1 osoby jest o 45% wyższe niż dla 2 osoby (popieram)

6. Jakie rodzaje testów można wykorzystać do oceny estymowanego modelu?

Podaj je i omów kryteria stosowania

test Walda dla poszczególnych współczynników modelu

Kryteria informacyjne: (im mniejsze tym lepiej)

- funkcja logarytmu z funkcji wiarygodności $-2\ln L$
- AIC = $-2\ln L + 2k$ (dokłada kare za liczbę zmiennych w modelu - k)
- BIC = $-2\ln L + k * \ln(n)$ (dokłada kare za liczbę zmiennych w modelu - k i liczbę obserwacji (n))

AUC - Area Under Curve - Pole pod krzywą ROC

Testy:

- test stosunku wiarygodności
- test punktowy
- test Walda

Jeżeli wielkość sprawdzianu z tych testów jest statystycznie istotna, daje to podstawę do **przyjęcia??** hipotezy zerowej, że przynajmniej jeden ze współczynników w populacji generalnej jest istotnie różny od zera

Kartkówka 2

Zadanie 1 (5 punktów) MNW w estymacji modelu regresji logistycznej

What is the probability of our data—seeing 7 heads in 10 coin tosses—as a function p ? The number of heads in 10 coin tosses is a binomial random variable with $N=10$ and $p=(\text{unknown}) p$.

$$\therefore P(7 \text{ heads}) = \binom{10}{7} p^7 (1-p)^3 = \frac{10!}{7! \cdot 3!} p^7 (1-p)^3$$

Metodą największej wiarygodności wyznacz wartość parametru p .
Ile wynosi: -2 (loglikelihood) ?

Rozwiązanie :

1. Take the log of the likelihood function.

$$Likelihood = \binom{10}{7} p^7 (1-p)^3 = \frac{10!}{7! \cdot 3!} p^7 (1-p)^3$$

$$\log Likelihood = \log \frac{10!}{7! \cdot 3!} + 7 \log p + 3 \log(1-p)$$

2. Take the derivative with respect to p .

$$\frac{d}{dp} \log Likelihood = 0 + \frac{7}{p} + \frac{-3}{1-p}$$

Log your memory →

*derivative of a constant is 0

*derivative $7f(x) = 7f'(x)$

*derivative of $\log x$ is $1/x$

*chain rule

3. Set the derivative equal to 0 and solve for p .

$$\frac{7}{p} - \frac{3}{1-p} = 0 \longrightarrow \frac{7(1-p) - 3p}{p(1-p)} = 0 \longrightarrow 7(1-p) = 3p$$

$$7 - 7p = 3p \longrightarrow 7 = 10p$$

$$p = \frac{7}{10}$$

RECAP:

$$\log \text{Likelihood} = \log \frac{10!}{7!3!} + 7 \log p + 3 \log(1-p)$$

$$\frac{d}{dp} \log \text{Likelihood} = 0 + \frac{7}{p} - \frac{3}{1-p}$$

$$\frac{7}{p} - \frac{3}{1-p} = 0$$

$$\frac{7(1-p) - 3p}{p(1-p)} = 0$$

$$7(1-p) = 3p$$

$$7 - 7p = 3p$$

$$7 = 10p$$

$$p = \frac{7}{10}$$

The actual maximum value of the likelihood might not be very high.

$$\text{Value of the Likelihood} = \binom{10}{7} (.7)^7 (.3)^3 = 120 (.7)^7 (.3)^3 = .267$$

Here, the $-2 \log$ likelihood (which will become useful later) is:

$$-2(\log \text{likelihood}) = -2(\ln(.267)) = 2.64$$

$$\text{Max}(\log(p^7(1-p)^3))$$

->

$$d/dp(\log(p^7(1-p)^3)) = (7 - 10p)/(p - p^2)$$

->

miejsce zerowe $P=0,7$

->

$$\text{Max}(\log(p^7(1-p)^3)) \text{ dla } p=0,7$$

1 wyznacz z definicji wartość odds ratio i podaj jego interpretację teoretyczną

https://www.google.pl/url?sa=t&source=web&rct=j&url=http%3A%2F%2Fweb.stanford.edu%2F~kcobb%2Fhrp261%2Flecture4.ppt&ved=0ahUKEwj3gfGOzNTLAhVIMnIKHXotDQoQFggMAE&usg=AFQjCNftVPlqLW8SITc8LZW_oQGOX9Nbw&sig2=gU3hM7x7TbJGNTXakoqzbu

slajd 28 i 29 - dokładnie przekopiować tę tabelę

	Exposure=1	Exposure=0
Disease = 1	$P(D / E) = \frac{e^{\alpha + \beta_1}}{1 + e^{\alpha + \beta_1}}$	$P(D / \sim E) = \frac{e^{\alpha}}{1 + e^{\alpha}}$
Disease = 0	$P(\sim D / E) = \frac{1}{1 + e^{\alpha + \beta_1}}$	$P(\sim D / \sim E) = \frac{1}{1 + e^{\alpha}}$

Odds Ratio for simple 2x2 Table

$$OR = \frac{\frac{e^{\alpha + \beta_1}}{1 + e^{\alpha + \beta_1}} \times \frac{1}{1 + e^{\alpha}}}{\frac{1}{1 + e^{\alpha + \beta_1}} \times \frac{e^{\alpha}}{1 + e^{\alpha}}} = \frac{e^{\alpha + \beta_1}}{e^{\alpha}} = e^{(\alpha + \beta_1) - \alpha} = e^{\beta_1}$$

(courtesy Hosmer and Lemeshow)

To samo inaczej

NiOk

1 wyznacz z definicji wartość odds ratio i podaj jego interpretację teoretyczną

$$1-P(X) = 1 - \frac{1}{1 + e^{-(\alpha + \sum \beta_i X_i)}} = \frac{e^{-(\alpha + \sum \beta_i X_i)}}{1 + e^{-(\alpha + \sum \beta_i X_i)}}$$
$$\frac{P(X)}{1-P(X)} = \frac{\frac{1}{1 + e^{-(\alpha + \sum \beta_i X_i)}}}{\frac{e^{-(\alpha + \sum \beta_i X_i)}}{1 + e^{-(\alpha + \sum \beta_i X_i)}}} = e^{(\alpha + \sum \beta_i X_i)}$$

Interpretacja teoretyczna:

Oznacza to że szansa dla osób które mają parametr $B_1=1$ jest e^{B_1} większa niż dla osób które ten parametr mają na poziomie $B_1=0$

?

2. Zapisz postać modelu w postaci logitu

The Logit Model

$$\log\left(\frac{P(D)}{1 - P(D)}\right) = \alpha + \beta_1 X_1$$
$$X_1 = \begin{cases} 1 & \text{if exposed (older)} \\ 0 & \text{if unexposed (younger)} \end{cases}$$

$$\log(P/[1-P]) = a + BX$$

Przykład:

Grupa odniesienia= **Adenocarcinoma**

Dwa porównania:

1. Adenosquamous (D=1) vs Adenocarcinoma (D=0)
2. Inne (D=2) vs Adenocarcinoma (D=0)

Korzystając z danych tablicy mamy:

CRUDE ODDS RATIO

$$\hat{OR}_{1vs0} = \frac{77 \times 34}{109 \times 11} = 2.18$$
$$\hat{OR}_{2vs0} = \frac{77 \times 39}{109 \times 18} = 1.53$$

		Actual	
		Positive	Negative
Predicted	Positive	TP	FP
	Negative	FN	TN

Gdzie (podaj określenie dla podanych oznaczeń oraz postacie niektórych mierników)

TP – True Positive - *poprawnie przewidziany sukces*

FP – FalsePositive - *niepoprawnie przewidziany sukces*

TN – True Negative - *poprawnie przewidziane niepowodzenie*

FN – False Negative - *niepoprawnie przewidziane niepowodzenie*

1. Współczynnik wrażliwości (sensitivity; recall) –

2. Współczynnik swoistości (specificity) –

3. Błąd I rodzaju (False positive Rate ; fallout) – *błąd polegający na odnalezieniu*
współkierownika, która w rzeczywistości jest prawdziwa.

4. Błąd II rodzaju (False negative Rate) – *błąd polegający na nieodnalezieniu*
współkierownika, która w rzeczywistości jest fałszywa.

5. Współczynnik precyzji (precision; positive predictive value) – *miara wykrywania*

6. Negative predictive value –

Współczynnik dokładności klasyfikacji (accuracy)

TP - true positive - liczba poprawnie przewidzianych sukcesów

FP - False positive - liczba niepowodzeń przewidywanych niepoprawnie jako sukces

TN - true Negative - liczba poprawnie przewidywanych niepowodzeń

FN - False negative - liczba sukcesów przewidywanych niepoprawnie jako niepowodzenie

Współczynnik wrażliwości (sensivity, recal) - $TP/(TP+FN)$ <- miara wykrywania sukcesów, % dobrze przewidzianych sukcesów w ogóle sukcesów w danych

Współczynnik swoistości (specificity) - $TN/(TN+FP)$ <- miara wykrywania niepowodzeń, % niepowodzeń dobrze przewidzianych jako negatywy (z ogółu negatywów w danych)

błąd 1 rodzaju - $FP/(FP+TN)$ <- odsetek fałszywych alarmów,

A nie będzie to: błąd polegający na odrzuceniu hipotezy zerowej, która w rzeczywistości nie jest fałszywa -> **to to samo**

błąd 2 rodzaju - $FN/(FN+TP)$

A nie będzie to: błąd polegający na nieodrżuceniu hipotezy zerowej, która jest w rzeczywistości fałszywa. -> **to to samo**

współczynnik precyzji (precision ; positive predicted value) $TP/(TP+FP)$

<http://www.uta.fi/sis/tie/tl/index/Rates.pdf>

negative predictive value - $TN/(TN+FN)$

współczynnik dokładności klasyfikacji $(TP+TN)/(P+N)$

Zadanie 5 (4 punkty) Jeśli założenie proporcjonalnych szans jest nie do utrzymania (iloraz szans zmienia się w zależności od kategorii), możemy dopasować zbiór równań regresji logistycznej, które będą posiadać zarówno indywidualne współczynniki kierunkowe jak i wyrazy stałe. Ten alternatywny model odzwierciedla tzn. odpowiedzi Y są w swojej naturze nominalne. W takim wypadku założymy, że mamy k nieuporządkowanych kategorii odpowiedzi wraz ze związanymi z nimi prawdopodobieństwami kategorii $p_j = P(Y=j|X)$, $j = 1, \dots, k$. Wtedy zbiór $k-1$ uogólnionych lub wielomianowych logitów ma postać

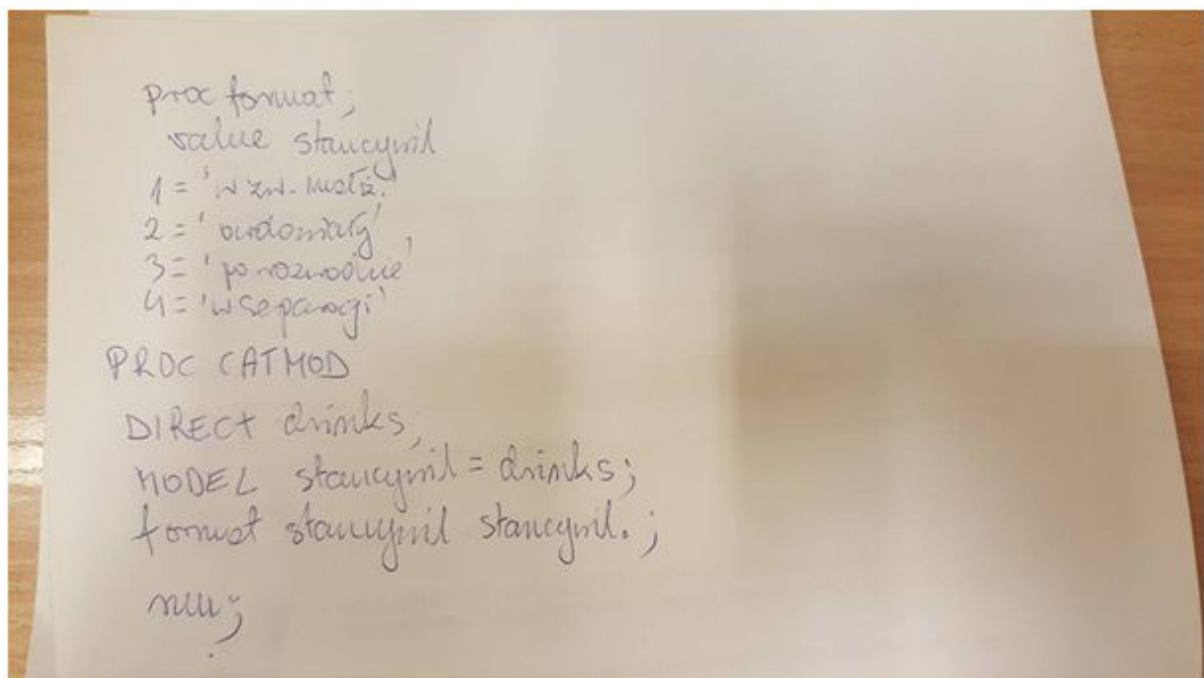
$$\log\left(\frac{p_j}{p_k}\right) = \beta_{0j} + \beta_{1j}X, j = 1, \dots, k-1 \text{ gdzie każda kolejna kategoria od 1 do}$$

$k-1$ jest porównywana z kategorią k lub ostatnią. Jak widać, system ten pozwala na istnienie $k-1$ różnych współczynników kierunkowych i wyrazów stałych. Założmy losową próbę $n=500$ dorosłych, którzy zostali spytani o ich stan cywilny (Y) i liczbę napojów alkoholowych spożywanych w ciągu tygodnia (X). Kategorie odpowiedzi nominalnych dla Y są następujące: 1, w związku małżeńskim; 2, Owdowiała; 3, po rozwodzie; 4, w separacji.

Aby określić zależność pomiędzy odpowiedziami Y i X, z wykorzystaniem modelu regresji logistycznej o postaci wielomianu, gdzie mamy dwie zmienne: *stan cywilny* (Y) – stan cywilny – to zmienna zależna, a *drinks* (X) – ilość napoi alkoholowych – to zmienna niezależna.

1. Napisz kod programu SAS na estymację modelu, zakładając, że informacje o 500 respondentów wprowadza się do SAS z ankiet.
2. Jak w postaci równania należy zapisać postać trzech uogólnionych logitów (w postaci równań):

Kod programu



1. Kod w SAS

```
proc format;  
value stancywil  
1="w związku"  
2="owdowiały"  
3="po rozwodzie"  
4="w separacji";
```

```
proc catmod;  
direct drinks;  
model stancywilny = drinks;  
format stancywilny stancywil.;  
run;
```

2. jak w postaci wielomianu należy zapisać postać trzech uogólnionych logitów (w postaci równań)

$$\log\left(\frac{p_1}{p_4}\right) = \beta_{01} + \beta_{11}X$$

$$\log\left(\frac{p_2}{p_4}\right) = \beta_{02} + \beta_{12}X$$

$$\log\left(\frac{p_3}{p_4}\right) = \beta_{03} + \beta_{13}X$$

$$\frac{p_1}{p_4} + \frac{p_2}{p_4} + \frac{p_3}{p_4} = e^{\beta_{01} + \beta_{11}X} + e^{\beta_{02} + \beta_{12}X} + e^{\beta_{03} + \beta_{13}X}$$

$$p_1 + p_2 + p_3 = p_4 (\dots)$$

$$p_1 + p_2 + p_3 + p_4 = 1$$

$$p_1 + p_2 + p_3 = 1 - p_4$$

$$1 - p_4 = p_4 [.]$$

$$1 = p_4 [.] + p_4$$

$$1 = p_4 ([.] + 1)$$

$$p_4 = \frac{1}{e^{\beta_{01} + \beta_{11}X} + e^{\beta_{02} + \beta_{12}X} + e^{\beta_{03} + \beta_{13}X} + 1}$$

czy to może chodzić o coś takiego?

czy bardziej o:

$$= \frac{1 - P(X)}{P(X)}$$
$$1: \log \left(\frac{P(X=1)}{P(X=2 \vee X=3 \vee X=4)} \right) =$$
$$= \log \left(\frac{P(X=1)}{P(X=2) + P(X=3) + P(X=4)} \right)$$
$$2: \log \left(\frac{P(X=2)}{P(X=1 \vee X=3 \vee X=4)} \right) =$$
$$= \log \left(\frac{P(X=2)}{P(X=1) + P(X=3) + P(X=4)} \right)$$